

VLA 내부 활성화에 나타나는 세밀 행동 단계 구조

박경태, 김상우, 오윤선[†]
한양대학교

rudxo1997@hanyang.ac.kr, [†] 교신저자 이메일

Fine-Grained Action-Phase Structure in the Internal Activations of a VLA Model

Kyungtae Park, Sangwoo Kim, Yoonseon Oh[†]
Hanyang Univ.

요약

Vision-Language-Action(VLA) 모델이 지금 어떤 작업 단계를 수행 중이라고 스스로 표상하는지 읽을 수 있다면, 이는 모델 행동의 설명가능성과 추론 시 제어의 출발점이 된다. 본 연구는 그 표상을 외부 관측이 아닌 내부 활성화에서 직접 읽는다. GR00T N1.5의 action head(DiT) 잔차 활성화를 라벨 없이 군집화하면, 사람이 정의한 primitive 행동 단계(reach, grasp 등)보다 3~4배 세밀한 상태 열이 나타난다(평균 구간 길이 4.3 vs 16.1 스텝). 각 군집은 특정 행동 단계에 국한되어 나타나며(순도 0.80), 시간 진행도 대조군보다 1.67 bits 높은 단계 정보를 담는다. 이 정보는 장면별 평균을 제거한 잔차에서도 유지되어 장면 암기로 환원되지 않는다. 이 구조는 군집 모델의 구조(AE $\leftrightarrow$ SAE)를 바꿔도 같은 시점에서 전환하고($z + 8.8 \sim +13.5$), 다른 수집 데이터에서도 재현된다($z + 4.3 \sim +5.1$). 즉 VLA 활성화에는 사람의 단계 정보보다 세밀하지만 단계 정합적인 하위 구조가 실재하며, 스텝 단위 온라인 관측이 가능하다.

I 서론

블랙박스로 동작하는 VLA 모델이 자율적으로 로봇 조작을 수행할수록, 모델이 지금 무슨 작업을 진행 중인지를 사람이 파악할 수 있어야 한다는 설명가능성(XAI) 요구가 커진다. 그 설명의 자연스러운 단위는 reach $\rightarrow$ grasp $\rightarrow$ transport 같은 시간적으로 확장된 primitive 행동 단계(phase)다 [9]. 단계를 파악하는 한 방법은 카메라 영상이나 궤적 같은 외부 관측을 분석하는 것이지만 [8], 외부 관측이 알려주는 것은 로봇이 궤보기에 무엇을 하고 있는가까지다. 모델이 스스로 무엇을 하고 있다고 생각하는가 — 즉 내부 표상이 가리키는 진행 단계 — 는 내부 활성화를 직접 읽어야만 알 수 있고, 궤보기 행동과 내부 표상이 어긋나는 순간(오인, 실패 전조)을 잡을 수 있는 것도 이 경로뿐이다. VLA 내부 표현을 해석하려는 최근 시도들은 회소 오토인코더(SAE)로 residual stream에서 과지·이송 같은 운동 primitive에 대응하는 feature를 찾아내거나 [3, 5], 선형 probe로 층별 상태를 관측하고 그 방향으로 활성화를 밀어 행동을 제어할 수 있음을 보였다 [4, 6]. 그러나 이들은 발견한 feature를 사람이 rollout 영상과 수동으로 정렬해 이름 붙일 뿐, 내부 표상이 사람이 정의한 행동 단계와 어떤 해상도로 대응하는지를 체계적으로 정량화하지 않는다. 내부 단계를 추론 중에 읽을 수 있으면 설명을 넘어 단계 조건부 개입 [6]이나 실패 감지 [7]의 조건 신호로도 쓸 수 있다. 본 연구는 GR00T N1.5(GR00T N1 [1]의 후속 릴리스)가 RoboCasa [2] 주방 조작을 수행하는 동안의 action head 활성화를 라벨 없는 군집화만으로 분석하고, 모델의 내부 단계 표상이 사람이 붙인 단계 라벨(GT)과 맺는 관계를 시간 대조군 대비 margin으로 정량화한다.

II 방법

데이터·특징. RoboCasa [2] 주방 조작 9개 태스크에서 GR00T N1.5 rollout을 수집하고, action head(DiT) 잔차 스트림 layer 12, denoising step 3의 49개 토큰 활성화를 평균해 스텝당 1536차원 특징을 얻는다. 사람 주석 GT 단계 라벨(태스크당 3~6단계)을 평가에만 사용한다. 두 데이터셋을 사용한다: (A) 23 에피소드(단계 경계 91개), (B) 독립 채수집 930 에피소드(10개 태스크, 89,766 스텝; 그중 1개 태스크는 30 에피소드 소표본).

군집화. PCA-64(whitening) 후 KMeans로 스텝별 활성화를 군집화한다($k=24$; 태스크별 분석은 $k=8$). 오토인코더 등 학습형 압축기는 이득이 오차 범위 내라 생략한다. train split에서만 군집을 만들고 평가 split은 k -NN($k=15$)으로 라벨을 옮긴다 — 재군집화가 없으므로 추론 중 스텝 단위 온라인 관측이 가능하다.

지표. 군집열이 담는 단계 정보는 MI(군집; GT 단계)로 재되, k 가 커지면 MI가 자동 상승하므로 시간 대조군 margin을 판정 기준으로 쓴다: 에피소드 진행도를 발견 군집 수와 같은 개수의 분위로 자른 “시계(clock)” 대조군의 MI를 빼준 값이다. 경계 정렬은 전환 위치를 에피소드 내에서 무작위로 혹은 300회 대비 z-score로 켤다.

III 결과

활성화 상태는 GT 단계보다 3~4배 세밀하다(그림 2a). 발견 상태의 평균 구간 길이는 4.3 스텝으로 GT 단계(16.1 스텝)의 약 1/4이다(전환율 18.4% vs 5.0%; 데이터셋 B에서도 6.0 vs 18.1 스텝, 전환 수 3.5배). 이 전환은 고정 리듬 아티팩트가 아니고(전환 위치의 주기성 없음), 전환 시점이 GT 경계와 정렬되지도 않는다($z - 1.0 \sim +0.5$ — 우연 수준). 그러나 발견 상태를 GT 단계 단위로 병합하면 경계 정렬이 유의해진다($z + 1.3 \sim +4.9$). 즉 활성화는 GT 단계를 그대로 재현하는 것이 아니라 그보다 잘게 쪼갬다. 이 세분화는 군집 수 k 를 크게 잡은 산술적 결과가 아니다: GT 단계 수(3~6)에 가까운 $k=8$ 에서도 구간 길이는 GT보다 짧게 유지되고(10개 중 9개 태스크), 에피소드당 전환 수가 상태를 한 번씩 지나는 단조 통과와 상한($k-1=7$ 회)을 넘는 태스크가 절반이다(최대 22회) — 상태가 재방문되는 구조로, k 만으로는 만들 수 없다. 반대로 한 태스크(OvenRack)는 같은 $k=8$ 에서 GT보다 굵게 병합되어, 해상도는 k 가 아니라 활성화가 정한다.

각 군집은 특정 단계에 국한된다(그림 1a, 그림 2b). 한 단계에서 나타난 군집은 다른 단계에서 잘 나타나지 않는다: 군집 $\rightarrow$ 단계 순도 0.80, MI 2.17 bits(상한 2.82), 시간 대조군 margin +1.665 bits. 군집이 최빈 단계 밖에서 나타나는 비율(off-phase rate)의 군집별 중앙값은 태스크 중앙값 0.22이며, 순수한 태스크에서는 0.001~0.06까지 내려간다(넓게 걸치는 태스크도 있어 최대 0.47 — 태스크별 편차가 있다). 단계 하나는 평균 2~3개 군집으로 세분되어(단계당 군집 수 1.3~2.7), 대응은 1:1이 아니라 다대일이다 — 이것이 위의 “세밀한 하위 분할”과 순도가 공존하는 이유다. 비디오 행동 분절에서 과분할은 통상 별점이지만, 여기서 세분은 phase-순수한 다대일 대응이며 그 판정 근거는 순도·MI·margin이지 경계 F1이 아니다.

단계 정보는 장면 암기로 환원되지 않는다(그림 1b). 활성화에는 장면(scene) 정보도 섞여 있다(태스크별 mi_scene 0.2~1.0 bits). 그러나 태스크 내 장면별 평균을 제거한 잔차에서 장면 정보는 대부분 사라지는 반면(mi_scene 중앙값 0.54 $\rightarrow$ 0.24 bits) 단계 margin은 소표본 퇴화 태스크 1개




Figure 1: (a) 군집×GT 단계 contingency(PPCC candle, k=8): 행을 최빈 단계로 정렬하면 블록-대각 구조 — 각 군집이 특정 단계에 국한됨(순도 0.910). (b) 장면 잔차화 후에도 단계 margin은 유지되고(9/9 양수) (c) 장면 MI는 붕괴한다.




Figure 2: (a) 발견 상태의 구간 길이는 GT 단계의 약 1/4~1/3. (b) 시간 대조군 대비 MI margin: 고정 k KMeans가 자율 k 방식보다 높다(데이터셋 A, k=24 기준 +1.665 bits).

를 제외한 9개 태스크 전부에서 양수로 유지된다(중양값 +0.34→+0.28; 3개 태스크는 오히려 상승).

구조는 모델·데이터를 바꿔도 재현된다. 같은 데이터에서 구조가 다른 두 압축 모델(AE, SAE)이 같은 스텝에서 전환하고(F1 0.66~0.75, 무작위 0.51~0.53, z +8.8~+13.5), 독립 재수집 데이터에서 새로 학습해도 같은 성질이 나타난다(seed 간 F1 0.55~0.58, z +4.3~+5.1). denoising 슬롯·장면·시드는 에피소드 내 상수화 전환의 원인이 될 수 없다.

세밀 단위는 하루 분석에서도 유용하다. 성공/실패 분리도를 단계 조건부로 켤 때, 발견 상태(태스크별 k=8)가 GT 단계보다 높은 분리도를 주는 태스크가 9개 중 4개였다(동급 1, 열세 1; 예: OpenDrawer AUROC 0.93/z4.5 vs GT 0.94/z2.3). 이는 탐색적 관찰이나, 세밀 단위가 사람 정의 단계의 단순 잡음이 아님을 시사한다.

IV 한계와 결론

GT 라벨 두 벌은 같은 주석 체계의 두 버전이라“어떤 단계 정의와도 어긋난다”는 주장은 할 수 없고, 전환 경계 자체는 GT와 정렬되지 않으므로 단계 판독의 근거는 군집 정체성(MI·순도)이지 경계 검출이 아니다. 길이 1의 짧은 상태가 구간의 31~37%를 차지하며 그 의미는 미검증이다.

결론: VLA 활성화에는 사람의 primitive 단계 정의보다 세밀하지만 단계 정합적인 상태 구조가 재현 가능하게 존재하며, k-NN 라벨 전이로 추론 중 온라인 판독이 가능하다. 즉 모델이 지금 무슨 작업을 진행 중이라고 표상하는지를 외부 관측 없이 내부에서 스텝 단위로 읽을 수 있으며, 이는 VLA 행동의 설명 신호이자 단계 조건부 개입[6]과 실패 감지[7]의 조건 신호가 된다.

References

- [1] NVIDIA GEAR Team, “GR00T N1: An Open Foundation Model for Generalist Humanoid Robots,” arXiv:2503.14734, 2025.
- [2] S. Nasiriany et al., “RoboCasa: Large-Scale Simulation of Everyday Tasks for Generalist Robots,” *RSS*, 2024.
- [3] A. Swann et al., “Sparse Autoencoders Reveal Interpretable and Steerable Features in VLA Models,” arXiv:2603.19183, 2026.
- [4] H. Buurmeijer et al., “Observing and Controlling Features in Vision-Language-Action Models,” arXiv:2603.05487, 2026.
- [5] X. Jin et al., “Event-Grounded Sparse Autoencoders for Vision-Language-Action Policies,” arXiv:2605.17204, 2026.
- [6] B. Häon et al., “Mechanistic Interpretability for Steering Vision-Language-Action Models,” *CoRL*, 2025.
- [7] Q. Gu et al., “SAFE: Multitask Failure Detection for Vision-Language-Action Models,” *NeurIPS*, 2025.
- [8] W. Wan et al., “LOTUS: Continual Imitation Learning for Robot Manipulation Through Unsupervised Skill Discovery,” *ICRA*, 2024.
- [9] R. S. Sutton, D. Precup, and S. Singh, “Between MDPs and Semi-MDPs: A Framework for Temporal Abstraction in Reinforcement Learning,” *Artificial Intelligence*, 112:181–211, 1999.