

# VLA 모델이 스스로 인지하는 작업 단계의 실시간 감지

박경태, 김상우, 오윤선<sup>†</sup>  
한양대학교

rudxo1997@hanyang.ac.kr, kimz1121@hanyang.ac.kr, <sup>†</sup>yoh21@hanyang.ac.kr

## Real-Time Detection of a VLA Model's Self-Perceived Action Phase

Kyungtae Park, Sangwoo Kim, Yoonseon Oh<sup>†</sup>  
Hanyang University

### 요약

Vision-Language-Action(VLA) 모델이 작업을 수행할 때 스스로 현재 어떤 작업 단계(action phase)를 진행 중인지 우리가 알 수 있다면, 이는 VLA 모델에 대한 설명 가능성을 높이고 추론 중 제어 및 개입을 가능하게 하는 출발점이 된다. 본 연구는 모델이 현재 수행 중인 action phase를 model의 내부 activation에서 감지할 수 있음을 보인다. GR00T N1.5 모델의 action head(diffusion transformer, DiT)의 residual stream activation을 clustering하면, 각 cluster는 특정 action phase에 국한되어 나타나고 다른 phase에서는 잘 나타나지 않는다. 이 대응을 이용하면 학습에 사용하지 않은 unseen scene에서도 한 step의 activation만으로 현재 phase를 0.82의 정확도로 감지할 수 있으며, 이는 경과 시간을 등분위로 분할하여 만든 시간 대조군과 관찰 기반 외부 모델 대조군을 웃돈다. 이 구조는 압축 모델을 SAE로 바꾸어 실험해도 재현된다. 즉 VLA activation에는 phase와 정합적인 구조가 존재해 이를 통해 추론 중 online action phase detection이 가능하다.




Figure 1: Unseen scene에서의 phase 감지 정확도. 막대는 instruction 10개의 중앙값, 흰 점은 instruction 별 값이다. 회색은 외부 정보만 쓰는 대조군, 파랑은 내부 activation이다.

### I. 서론

VLA 모델은 내부를 이해하기 힘든 블랙박스이지만 실제 로봇을 조작하므로, 모델이 지금 무슨 작업을 진행 중이라고 인지하는지 사람이 파악할 수 있어야 한다. 본 논문에서 action phase란 manipulation task를 의미 단위로 나누었을 때 로봇이 수행하고 있는 하위 작업(subtask)을 의미한다. 같은 subtask가 한 task 안에서 여러 번 다시 등장할 수도 있다. 예컨대 Pick & Place task는 reach, grasp, transport, place의 phase로 구성된다[11]. 현재 phase를 파악하는 방법으로는 카메라나 센서로 얻은 환경, 로봇의 상태정보를 통해 외부 관찰자 모델을 학습시켜서 얻는 방법이 있다[10]. 하지만 외부 관찰은 로봇이 겉보기에 무엇을 하는지 알려줄 뿐이며, 모델이 스스로 어떤 작업을 하고 있다고 인지하는지는 내부 activation을 직접 읽어야만 알 수 있고, 이는 겉보기 행동과 모델의 인지가 어긋났을 때 수정을 위한 전제 조건이다. VLA 내부 표현을 해석하려는 최근 시도들은 Sparse Auto Encoder(SAE)나 linear probe로 primitive action에 대응하는 feature를 찾고 그 방향으로 steering까지 보였으나[3, 4, 5, 8], feature의 이름은 사람이 rollout 영상과 대조해 수동으로 붙이며, 내부 표상이 사람이 정의한 phase를 얼마나 정확히, 어떤 단위로 담는지는 정량화하지 않는다. VLA의 내부 phase를 추론 중에 online으로 읽을 수 있으면 설명을 넘어 조건부 개입이나 실패 감지[9]의 조건 신호로 활용할 수 있다. 본 연구는 GR00T N1.5[1]가 RoboCasa[2] 주방 조작을 수행하는 동안의 activation을 Auto Encoder(AE)와 clustering으로 분석해, 모델 내부 phase가 사람이 정의한 phase와 갖는 관계를 감지 정확도와 Mutual Information(MI) margin으로 정량화한다.

### II. 방법

**Data.** RoboCasa 주방 조작 환경에서 GR00T N1.5의 rollout을 수집한다. 5개 task(OpenDrawer, PnPCounterToCab, Oven-

Rack, DishwasherRack, CoffeeSetupMug)에 속하는 10개 instruction마다 10개 scene에서 10회씩 총 1,000 rollout을 수집하였다. 모델이 1회 추론할 때마다 action head(DiT)의 residual stream activation을 캡처하며, 이 추론 1회를 한 추론 스텝으로 삼는다. 이 activation은 12번째 layer의 마지막 denoising step에서 49개 토큰을 평균한 1,536차원 벡터이고, GT phase 라벨은 그 추론이 일어난 시점의 라벨을 사용한다.

Detector의 학습과 평가는 instruction별로 진행하며 dataset은 scene 단위로 분리한다. 10개 scene 중 8개를 학습용, 2개를 평가용으로 나누고, 이러한 분할을 무작위로 3가지 구성한다. 분할마다 표준화, AE, clustering, phase 매핑을 학습 scene만으로 새로 fitting하며, 세 분할의 평가 결과를 평균해 보고한다. 사람이 라벨링한 phase 라벨은 AE와 KMeans 학습에는 쓰지 않으며, cluster를 최빈 phase에 대응시키는 매핑과 평가 시 채점에만 사용한다.

**Clustering.** Raw activation 1,536차원을 AE를 통해 16차원 latent 벡터로 압축한 뒤 KMeans로 clustering한다. Cluster 수는  $k = 8$ 을 사용한다. 사람이 라벨링한 phase 수(3-6)를 넘는  $k$ 에서 감지 성능이 평탄화 돼 특정  $k$ 에 의존적이지 않음을 결과에서 보인다(Figure 3). Cluster 중심은 학습 split에서만 만든다. 추론 중에는 매 추론 스텝마다 얻는 activation을, 학습한 AE에 그대로 통과시켜 latent 값을 얻고 가장 가까운 중심에 매핑해 cluster를 추정한다. 이 방식은 추론 중 학습이나 clustering이 필요 없고, 해당 스텝의 activation 하나와 고정된 중심만으로 감지하여 과거·미래 스텝을 필요로 하지 않으므로 online detection이 가능하다.

**Baseline.** 각 instruction 별로 phase는 순서대로 진행되는 경향이 있다. 따라서 activation이 아니라 단순히 진행도만으로 판단하는 detector도 어느 정도 phase를 맞힌다. 이 뚝을 빼기 위한 시간 대조군은 에피소드 시작부터의 경과 스텝 수를 발견된 cluster 수와 같은 개수의 구간으로 등분위 분할한 후, 각 구간별로 학습 데이터에서의 최빈값을 phase로 판단하는 baseline이다. 또한 외부 관찰만으로 phase를 나누는 기존 방법과 비교하기 위해, 관찰 기반 외부 모델 대조군으로 기존 연구[5]의 이벤트 발견 파이프라인을 채택한다. 저자가 공개한 구현을 수정 없이 사용하여, end-effector 궤적에서 AWE[6]로 waypoint를 추출하고 그 주변 프레임의 SigLIP[7] 시각 임베딩에 로봇 상태와 진행도를 이어붙인 descriptor를 clustering해 이벤트를 얻는다.

**Metric.** 주 지표는 margin과 정확도이다. 스텝  $i$ 의 cluster 라벨을  $z_i \in \{1, \dots, k\}$ , 사람이 붙인 GT phase를  $y_i$ 라 하자. Cluster 라벨을 알았을 때 phase에 대한 불확실성이 얼마나 줄어드는지를 Mutual Information(MI)

$$I(Z; Y) = \sum_k \sum_c p(k, c) \log_2 \frac{p(k, c)}{p(k)p(c)}$$

로 측정한다. 여기서  $p(k, c)$ 는 전체 스텝 중 cluster가  $k$ 이면서 phase가  $c$ 인 비율이다. 다만 MI는 cluster 수가 늘면 자동으로

커지므로, 같은 상태 수를 갖는 시간 대조군의 MI를 뺀 값을 사용한다.

$$\text{margin} = I(Z; Y) - I(Z_{\text{clock}}; Y). \quad (1)$$

정확도는 감지한 cluster가 매핑된 phase와 GT phase가 일치하는 비율로 구한다.

### III. 결 과

**VLA 내부 activation 한 스텝만으로 phase를 감지 할 수 있다.** Instruction별 unseen scene 정확도의 중앙값은 0.82이다 (Figure 1). 시간 대조군은 정확도 0.67이며, 관찰 기반 외부 모델 대조군[5]은 0.65이다. 같은 환경에서 activation cluster(ours)는 10개 instruction 중 9개에서 관찰 기반 외부 모델 대조군을 앞서며, 모든 방법이 약 0.5의 정확도를 보이는 “Fully slide the top dishwasher rack out” instruction에서는 예외이다. 즉 내부 activation이 가진 phase 정보가 가장 풍부하고 정확하다.

**각 cluster는 특정 phase에 국한된다.** 한 phase에서 나타난 cluster는 다른 phase에서 잘 나타나지 않는다. Cluster와 phase의 동시 출현 비율  $p(k, c)$ 를 나타낸 행렬에서는 특정 cluster는 특정 phase에 주로 나타남이 보인다(Figure 2a). 시간 대조군의 MI 중앙값은 0.279 bits이며, margin의 중앙값은 +0.343 bits이다. 모든 instruction에서 양수이므로 단순히 진행도만 가지고 판단하는 것보다 정보량이 풍부함을 알 수 있다(Figure 2b).  $k$ 가 GT phase 수보다 커서 한 phase를 여러 cluster가 나눠 갖더라도 각 cluster는 특정 phase에 국한되므로 이 방식의 높은 정보량을 여전히 지 지한다.

**Phase 정보는 장면 압기로 환원되지 않는다.** Activation에는 scene 정보도 섞여 있다(instruction별 scene과의 MI 0.02~0.86 bits). 그러나 scene별 평균을 제거한 잔차에서 scene 정보는 중앙 값 0.44에서 0.27 bits로 크게 줄어드는 반면, phase margin +0.34에서 +0.31로 10개 instruction 전부에서 양수로 유지된다(Figure 2b).

**Cluster 전환은 압축 모델에 관계없이 일관된다.** Cluster 전환이 특정 압축 모델의 산물이 아님을 확인하기 위해, 같은 activation을 AE와 SAE로 각각 압축·clustering했다. 각 모델은 에피소드의 스텝마다 cluster를 하나씩 배정하므로 앞 step과 cluster가 달라지는 지점을 전환으로 정의할 수 있다. 두 모델이 낸 전환을  $\pm 1$ 스텝 이내에서 짝지었다. 짝지어진 비율을 AE 전환 기준(precision)과 SAE 전환 기준(recall)으로 구해 조화평균한 값이 전환 일치 F1이며, 전환 개수는 두고 위치만 무작위로 흘은 상태 열 300개의 F1 분포로  $z$ 를 구한다. 두 모델의 전환 일치율은 F1 0.66~0.75,  $z + 8.8 \sim +13.5$ 을 보인다. 즉 activation에는 전환 시점 정보가 존재한다.

### IV. 한계와 결론

**한계.** 평가는 단일 모델(GR00T N1.5)·단일 벤치마크(RoboCasa, 시뮬레이션)에 한정되어 다른 VLA나 실제 로봇으로의 일반화는 확인하지 않았다. GT phase 라벨은 한 명의 연구자가 부여한 것이라 정확도의 절대값은 그 기준에 의존한다. 다만 모든 방법을 같은 라벨로 채점하므로 비교에는 영향이 같다. 또한 본 연구는 표상을 읽는 것이며, 개입해 행동을 바꾸는 것은 별개의 검증을 요한다.

**결론.** VLA의 action head activation에는 사람이 정의한 phase와 정합적인 구조가 있음을 비지도 clustering으로 확인 할 수 있으며, 이를 이용하면 unseen scene에서도 한 스텝의 activation만으로 현재 phase를 정확도 0.82로 감지할 수 있다. 이 감지는 추론 중 매 스텝 online으로 그대로 수행되므로, phase 조건부 개입·실패 감지의 조건 신호로 나아가는 출발점이 된다.

### 참 고 문 헌

- [1] NVIDIA GEAR Team, “GR00T N1: An Open Foundation Model for Generalist Humanoid Robots,” arXiv:2503.14734, 2025.
- [2] S. Nasiriany et al., “RoboCasa: Large-Scale Simulation of Everyday Tasks for Generalist Robots,” *RSS*, 2024.
- [3] A. Swann et al., “Sparse Autoencoders Reveal Interpretable and Steerable Features in VLA Models,” arXiv:2603.19183, 2026.
- [4] H. Buurmeijer et al., “Observing and Controlling Features in Vision-Language-Action Models,” arXiv:2603.05487, 2026.
- [5] X. Jin et al., “Event-Grounded Sparse Autoencoders for Vision-Language-Action Policies,” arXiv:2605.17204, 2026.
- [6] L. X. Shi, A. Sharma, T. Z. Zhao, and C. Finn, “Waypoint-Based Imitation Learning for Robotic Manipulation,” *CoRL*, 2023.

- [7] X. Zhai, B. Mustafa, A. Kolesnikov, and L. Beyer, “Sigmoid Loss for Language Image Pre-Training,” *ICCV*, 2023.
- [8] B. Häon et al., “Mechanistic Interpretability for Steering Vision-Language-Action Models,” *CoRL*, 2025.
- [9] Q. Gu et al., “SAFE: Multitask Failure Detection for Vision-Language-Action Models,” *NeurIPS*, 2025.
- [10] W. Wan et al., “LOTUS: Continual Imitation Learning for Robot Manipulation Through Unsupervised Skill Discovery,” *ICRA*, 2024.
- [11] R. S. Sutton, D. Precup, and S. Singh, “Between MDPs and Semi-MDPs: A Framework for Temporal Abstraction in Reinforcement Learning,” *Artificial Intelligence*, 112:181–211, 1999.




Figure 2: (a) Cluster와 GT phase 출현 연관성 행렬. 세로축은 cluster에 임의로 부여한 index이다. 이는 특정 cluster는 특정 phase에 주로 국한되어 나타남을 보여준다. (b) Activation에서 scene별 평균값을 뺀 후의 phase에 대한 margin. (c) activation이 scene에 대해서 얼마나 설명하는지를 나타내는 그래프.




Figure 3: 감지 정확도의  $k$ 에 대한 강건성. GT phase 수(3-6, 회색 대역)를 넘는  $k \geq 8$ 에서 성능이 평탄해진다(0.82-0.88). 흐린 선은 각 instruction별 accuracy 그래프이다.